A 部分

任务一

reduceCFG 调用 PoRECFGReducer::inspectCFGNode 化简节点,而reduceCFGComplete 调用 PoRECFGReducer::inspectCFGNodeComplete 化简节点。这个将会在化简循环语句中使用到。

任务二

inspectCFGNodeComplete 中的实现:

```
if(node->getSuccNum() == 1){
    //后继节点为1
    ShPtr<CFGNode> succ = node->getSucc(0);
    succs = succ->getSuccessors();
    ShPtr<Statement> gotoBody = getGotoBody(node, succ);
    reduceNode(node, gotoBody, succs, true);
```

InspectCFGNode 中的实现:

```
bool Porecfgreducer::tryReduceSequence(ShPtr<CfGNode> node) {
   * TODO: 识别并化简顺序结构,注意有些顺序结构有多个前继节点
   // 获取后继节点数目
   std::size_t succNum = node->getSuccNum();
   if(!node) return false;
   if(succNum == 1){
       ShPtr<CFGNode> succ = node->getSucc(0);
       if(succ && succ != node && succ->getPredsNum() == 1){
           //两个节点之间只有一条连线才是顺序结构
          //要排除掉自循环的节点
          ShPtr<Statement> succBody = succ->getBody();
          CFGNodeVector nextSuccessors = succ->getSuccessors();
          //不覆盖原来的语句
          reduceNode(node, succBody, nextSuccessors, true);
          return true;
   return false;
```

假设 A、B 两个节点为顺序结构,顺序结构的关键就是**保证 A 的后继节点只有一个 B,并且 B 的前继节点只有一个 A(否则会进入死循环)**。而且要排除自己指向自己的情况。

然后根据 reduceNode 的接口来获取 succBody,nextSuccessors 即可。

两种规则对比:

- 1. inspectCFGNode 需要考虑的情况更多,否则会造成死循环
- 2. inspectCFGNodeComplete 只需要考虑后续节点为一这一个条件

完成任务前后不同 sequen.bin.c 对比:

```
int main(int argc, char ** argv) {
          char * v1[1];
          char * v2[1];
          puts("Main Start");
          int64_t v3 = (float64_t)g1;
          v1[0] = (char *)&v3;
          v2[0] = (char *)*(int64 t *)*(int64 t *)0x100004010;
          _execve("/bin/bash", v1, v2);
          _puts("Done");
前:
     int main(int argc, char ** argv) {
         char * v1[1];
         char * v2[1];
        _p"ts("Main Start");
         in | t v3 = (float64_t)g1;
         v1[0] = (char *)&v3;
         v2[0] = (char *)*(int64_t *)*(int64_t *)0x100004010;
         _execve("/bin/bash", v1, v2);
int32_t v4 = _puts("Done");
int64_t v5 = *(int64_t *)0x100004008;
         if (*(int64_t *)v5 == *(int64_t *)*(int64_t *)0x100004008) {
             return 0;
         ___stack_chk_fail((int64_t)v4);
后: <sup>}</sup>
前后基本没差别
```

任务三

inspectCFGNodeComplete 的实现:

主要需要考虑的是当前节点的 succs 应该如何获取。

- 1. 如果是简单 if 语句, 实现 cond 语句会跳转到 true 语句, 那么下
 - 一节点就是 node->getSucc(0)->getSucc(0)

- 2. 如果是简单 if 语句, 实现 cond 语句会跳转到 false 语句, 那么下一个节点就是 node->getSucc(1)->getSucc(0)
- 3. 如果是 if-else 语句, 那么下一节点直接就是 node->getSucc(0)->getSucc(0)
- 一、 If 结构的识别与化简

首先是 if 结构的判断: if (node->getSuccNum() == 2 && !isSwitch(node))

注意: 判断条件不能有!isLoopHeader(node), 不然会识别不出来 while-if 的结构

然后根据 getIfClauseBody, getIfStmt 的接口来确定需要获取的变量。

```
if(node->getSuccNum() == 2 && !isSwitch(node) ){
    ShPtr<Expression> cond = getNodeCondExpr(node);
    ShPtr<CFGNode> succ_true = node->getSucc(0);//true分支
    ShPtr<CFGNode> succ_false = node->getSucc(1);//false分支
    ShPtr<Statement> ifBody;
    ShPtr<Statement> elseBody;
    CFGNodeVector nextSuccessors;
    ShPtr<CFGNode> ifSucc;//if结构的后继节点
```

注意这里的 ShPtr<Expression> cond = getNodeCondExpr(node);必须确定是 if 结构才能使用,否则会报错。

接下来需要判断三种情况,和上述 inspectCFGNodeComplete 的实现一样:

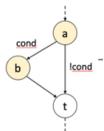
```
if(succ_true->getPredsNum() == 1 && succ_true->getSuccNum() == 1 && succ_true->getSucc(0) == succ_false){
    //简单的详结构。分为两种情况:cond是有定的
    ifSucc = succ_true->getSucc(0);//
    inextSuccessors = (ifSucc);
    LOG << "Try reduce if-else: " << node->getDebugStr() << "\n";

    // 获得if分支代码块
    ifBody = getIfClauseBody(node, succ_true , ifSucc);
    elseBody = getIfClauseBody(node, nullptr , ifSucc);
elseBody = getIfClauseBody(node, nullptr , ifSucc);
elseBody = getIfClauseBody(node, nullptr , ifSucc);

ifSucc = succ_false->getPredsNum() == 1 && succ_false->getSuccNum() == 1 && succ_false->getSucc(0) == succ_true){
    //简单if运句: cond是否定的
    ifSucc = succ_false->getSucc(0);
    nextSuccessors = (ifSucc);
    cond = getLogicalNot(cond);

    // 获得if分支代码块
    ifBody = getIfClauseBody(node, nullptr , ifSucc);
elseBody = getIfClauseBody(node, nullptr , ifSucc);
elseBody = getIfClauseBody(node, succ_false , ifSucc);
```

需要注意的是,如果是简单 if 结构, 实现 cond 语句会跳转到 true 语句, 那么



elseBody 的分支跳转节点是 nullptr.

根据这张图可以看出来原因

是 b 和 a 都有共同的后继节点,不是 if-else 结构。

如果是简单 if 结构, 实现 cond 语句会跳转到 false 语句, 那么 ifBody 的分支跳转节点是 nullptr。理由同上。注意同时还要有 cond = getLogicalNot(cond);这是

```
if(ifBody == nullptr){     return false;}
ShPtr<IfStmt> ifStmt = getIfStmt(cond,ifBody,elseBody);
reduceNode(node, ifStmt, nextSuccessors, true);
return true;
```

为了确保后面

ifStmt 的统一进行。

以 branch_if.bin.c 为例,

```
int main(int argc, char ** argv) {
     _puts("Main Start");
前: }
```

其他包含 if 结构的也一眼能够正确识别 if 结构。

与 Complete 的对比:

这个方法需要考虑的情况更多,但是能够更加精确地识别 if-else 结构和简单的 if 结构。Complete 需要考虑的情况更少。

二、 Switch 结构的识别与化简

遇到的主要困难是:对 API 的理解出现误差。误以为 getSwitchStmt 的第一个参数是 SwitchClause = std::pair<ExprVector, ShPtr<CFGNode>>的第二个参数。根据 getSwitchStmt()的第三个接口 const SwitchClauseBodyVector & clauses (switch语句的所有分支)发现需要先循环一遍 switch语句获得所有分支。

```
//根据SwitchClauseVector来生成SwitchClauseBodyVector
for(int i=0; i<switchClauses.size(); i++){
    //需要进行正确的初始化
    ShPtr<SwitchClauseBody> switchBody = std::make_shared<SwitchClauseBody>()
    switchBody->first = switchClauses[i]->first;

    //生成一条新的 break 语句
    ShPtr<BreakStmt> breakStmt = getBreakStmt(switchClauses[i]->second,target switchClauses[i]->second->appendToBody(breakStmt);

switchBody->second = switchClauses[i]->second->getBody();
    bodyVector.push_back(switchBody);
}
```

其中因为要加上 break 语句所以找了另一个 API appendToBody。

需要注意的是, switchBody 要先进行正确的初始化, 否则后面->first 会报错, 空指向。

然后获得 cond 即可。

```
ShPtr<Expression> cond = getNodeCondExpr(node);//这里是node
//生成一条新的 switch 分支语句,
ShPtr<SwitchStmt> switchStmt = getSwitchStmt(node, cond, bodyVector);
reduceNode(node, switchStmt, succs, true);
```

完成前:

```
if (v1 == 2 || v1 == 1) {
   _puts("Case 1/2");
```

完成后:

```
int main(int argc, char ** argv) {
    int32_t v1 = argc;
    if (v1 == 2 || v1 == 1) {
        _puts("Case 1/2");
    } else {
        switch (v1) {
            case 3: {
                _puts("Case 3");
                break;
        }
        case 5: {
                _puts("Case 5");
                break;
        }
        default: {
                _puts("Default");
                break;
        }
    }
    return 0;
}
```

与源代码语义相同。

任务四:

看到提示的 getWhileLoopStmt()需要用到 body, 然后 getWhileBody()要求是自循环节点,所以想到要先考虑自循环节点。

```
if(node->getSuccNum() == 1 && node->getSucc(0) == node){
    ShPtr<ConstBool> cond = getBoolConst(true);
    ShPtr<Statement> body = getWhileBody(node);
    ShPtr<WhileLoopStmt> whileStmt = getWhileLoopStmt(node, cond, body);
    CFGNodeVector succs = {};
    reduceNode(node, whileStmt, succs, false);
    return true;
```

在这里遇到的困难: 一开始没有正确定位自循环节点的条件 node->getSuccNum() == 1 导致一直报错。后来发现如果 node->getSuccNum() > 1, 那么会被后面的 reduceCFGComplete(node)识别。

这样定位能够识别所有 while(true)语句。但是无法识别 while (i < argc)语句,只能通过 goto 来解决。

自循环节点不会跳转到其他节点,所以判断条件恒为 true,并且也没有后续节点 succs。

```
int main(int argc, char ** argv) {
    _puts("Main Start");
    while (true) {
        _puts("Hi");
    }
}
```

完 成 后

与 源 代 码

```
int main(int argc, char **argv) {
    puts("Main Start");
    while (1) {
        puts("Hi");
    }
    puts("Done");
    return 0;
}
```

·语义相同。

再考虑非循环节点的情况。参考给出的提示。

这里直接使用提示的 API: reduceCFG, reduceCFGComplete

需要注意的是在使用之前都要确保这个循环没有被化简过,否则会报错。

reduceCFG 调用 PoRECFGReducer::inspectCFGNode 化简节点,而reduceCFGComplete 调用 PoRECFGReducer::inspectCFGNodeComplete 化简节点。把 while 语句转化成多个 if-goto 语句的结合。

生成的结果:

```
int main(int argc, char ** argv) {
    _puts("Main Start");
   int32_t v1 = argc;
   int32_t v2 = -v1;
   if (v2 < 0 == (v2 & v1) < 0) {
        return 0;
   int32_t v3 = 0;
 lab_0x100003f60:
    _puts((char *)*(int64_t *)(8 * (int64_t)v3 + (int64_t)argv));
   v3++;
   int32 t v4 = v3 - v1;
   if (v4 < 0 == ((v4 ^ v3) & (v3 ^ v1)) < 0) {
       return 0;
   goto lab_0x100003f60;
}
                 int main(int argc, char **argv)
                     puts("Main Start");
                     int i = 0;
                     while (i < argc) {
                          puts(argv[i]);
                          i++;
```

return 0;

与源代码语义相似

B部分

以这个片段为例:

```
define i64* @function_100003d7c(i32 %size) {
dec_label_pc_100003d7c:
 %0 = sext i32 %size to i64
 store i64 %0, i64* @x0
; 0x100003d7c
 store volatile i64 4294983036, i64* @_asm_program_counter
 store i64 4294983680, i64* @x16
; 0x100003d80
 store volatile i64 4294983040, i64* @_asm_program_counter
 %1 = load i64, i64* @x16
 %2 = add i64 %1, 16
 %3 = inttoptr i64 %2 to i64*
 %4 = load i64, i64* %3
 store i64 %4, i64* @x16
; 0x100003d84
 store volatile i64 4294983044, i64* @ asm program counter
 %5 = load i64, i64* @x0
 %6 = trunc i64 %5 to i32
 %7 = call i64* @_malloc(i32 %6)
 %8 = ptrtoint i64* %7 to i64
 store i64 %8, i64* @x0
 %9 = ptrtoint i64* %7 to i64
 store i64 %9, i64* @x0
 %10 = load i64, i64* @x0
 %11 = inttoptr i64 %10 to i64*
 ret i64* %11
LLVM 值 Def: %0 = sext i32 %size to i64
 被使用: store i64 %0, i64* @x0
LLVM 值 Def: store i64 %0, i64* @x0
 使用了: %0 = sext i32 %size to i64
变量 Def: 0x5b1faebe4088
        %5 = load i64, i64* @x0
 被使用:
LLVM 值 Def:
```

```
; 0x100003d7c
 store volatile i64 4294983036, i64* @_asm_program_counter
变量 Def: 0x5b1faf125b28
LLVM 值 Def: store i64 4294983680, i64* @x16
变量 Def: 0x5b1faebe5288
 被使用: %1 = load i64, i64* @x16
LLVM 值 Def:
; 0x100003d80
 store volatile i64 4294983040, i64* @ asm program counter
变量 Def: 0x5b1faf125b28
LLVM 值 Def: %1 = load i64, i64* @x16
 被使用: %2 = add i64 %1, 16
 使用了: store i64 4294983680, i64* @x16
LLVM 值 Def: %2 = add i64 %1, 16
 被使用: %3 = inttoptr i64 %2 to i64*
 使用了: %1 = load i64, i64* @x16
LLVM 值 Def: %3 = inttoptr i64 %2 to i64*
 被使用: %4 = load i64, i64* %3
 使用了: %2 = add i64 %1, 16
LLVM 值 Def: %4 = load i64, i64* %3
 被使用: store i64 %4, i64* @x16
 使用了: %3 = inttoptr i64 %2 to i64*
LLVM 值 Def: store i64 %4, i64* @x16
 使用了: %4 = load i64, i64* %3
变量 Def: 0x5b1faebe5288
LLVM 值 Def:
; 0x100003d84
 store volatile i64 4294983044, i64* @_asm_program_counter
变量 Def: 0x5b1faf125b28
LLVM 值 Def:   %5 = load i64, i64* @x0
 被使用: %6 = trunc i64 %5 to i32
 使用了: store i64 %0, i64* @x0
LLVM 值 Def:   %6 = trunc i64 %5 to i32
 被使用: %7 = call i64* @_malloc(i32 %6)
 使用了: %5 = load i64, i64* @x0
LLVM 值 Def:   %7 = call i64* @_malloc(i32 %6)
 被使用: %8 = ptrtoint i64* %7 to i64
 被使用: %9 = ptrtoint i64* %7 to i64
 使用了: %6 = trunc i64 %5 to i32
LLVM 值 Def:   %8 = ptrtoint i64* %7 to i64
 被使用: store i64 %8, i64* @x0
 使用了: %7 = call i64* @_malloc(i32 %6)
LLVM 值 Def: store i64 %8, i64* @x0
 使用了: %8 = ptrtoint i64* %7 to i64
```

变量 Def: 0x5b1faebe4088

LLVM 值 Def: %9 = ptrtoint i64* %7 to i64

被使用: store i64 %9, i64* @x0

使用了: %7 = call i64* @_malloc(i32 %6)

LLVM 值 Def: store i64 %9, i64* @x0 使用了: %9 = ptrtoint i64* %7 to i64

变量 Def: 0x5b1faebe4088

被使用: %10 = load i64, i64* @x0 LLVM 值 Def: %10 = load i64, i64* @x0 被使用: %11 = inttoptr i64 %10 to i64*

使用了: store i64 %9, i64* @x0

LLVM 值 Def: %11 = inttoptr i64 %10 to i64*

被使用: ret i64* %11

使用了: %10 = load i64, i64* @x0

LLVM 值 Def: ret i64* %11

使用了: %11 = inttoptr i64 %10 to i64*

其中,对于%0的情况,它通过"sext i32 %size to i64"这条指令定义,然后被使用在"store i64 %0, i64* @x0"这个存储操作中,从而形成了 DU 链。

对于%5 等变量,通过 load 指令加载数据到寄存器,然后进行一系列计算和转换操作,最终将结果存储回内存中,这些变量的定义和使用关系形成了 DU 链和 UD 链。

理解:

播

UD 链: 使用的变量在哪里被定义

UD 链: 定义的变量在哪里被使用

UD 链: 进行循环不变计算的检测,判定变量 x 是否未经定值就被引用,复制传

DU 链: 无用代码的删除, 循环中的代码外提

DU 链和 UD 链的形成使得我们能够准确地定位变量的定义和使用位置。简化了

数据流分析的复杂性。通过这些链,能够轻松追踪数据流,识别变量间的依赖关系,从而帮助化简数据流分析。

任务二

2.2.1

- 1. 插件具体是如何识别形式参数和实际参数的
- (1) collectAllCalls 调用 createDataFlowEntry, createDataFlowEntry 调用 collectDefArgs, 主要看 collectDefArgs 函数。

可以看到识别形式参数的主要方式是利用定值-使用分析,查找不在通用寄存器和堆栈变量中的 load 指令,分析函数中的未初始化引用。即:指令使用的操作数,UD 链为空。

(2) collectAllCalls 调用 addDataFromCall, addDataFromCall 调用 collectCallArgs 函数, 通过 collectStoresBeforeInstruction 收集和识别调用指令前的 store 指令, 并

且能够过滤掉与上下文不相关的存储指令。

- 2. 在生成优化后代码时(applyTolr), 分别如何使用识别的形式参数和实际参数
- (1) 修改函数定义:使用 IrModifier::modifyFunction()函数修改函数的定义。该函数会生成一个新的函数定义,并替换原有的函数定义。
- (2) 更新函数调用: 通过调用 de.setCalledValue(newFnc)更新函数调用指令中的被调用函数值,使其指向新生成的函数定义。
- (3)构建参数列表和类型:根据收集到的形式参数信息(de.args()和de.argTypes()),构建函数的参数列表和类型列表。如果某个参数的类型未收集到,则使用ABI的默认类型作为该参数的类型。
- 3.插件除了 collectAllCalls 外其它部分是怎么帮助优化函数类型识别和代码生成的

collectCallSpecificTypes 函数分析调用约定。针对变参函数,尝试从函数调用中提取格式字符串(如 printf 风格的格式字符串),并使用这些信息来推断参数类型。这对于提高函数类型识别的准确性非常有帮助。

collectDefRets 和 collectCallRets 函数分别收集函数定义中的 return 指令之后的 load 指令(对于返回值类型分析)和函数调用之后的 load 指令(对于返回值的

使用分析)。这有助于确定函数的返回类型,以及如何在后续代码中使用这些返回值。

2.2.2 优化目标 1

根据提示修改 etdec/src/bin2llvmir/providers/abi/arm64.cpp。关注到 abi 部分的 if (!_abi->isGeneralPurposeRegister(ptr) && !_abi->isStackVariable(ptr))。其中

```
bool AbiArm64::isGeneralPurposeRegister(const llvm::Value* val) const
{
    uint32_t rid = getRegisterId(val);
    return ARM64_REG_X0 <= rid && rid <= ARM64_REG_X30;
}</pre>
```

的范围是 X0-X30,但是根据 ARM64 架构下调用约定,函数实际上只使用 X0 到 X7 之间的寄存器传递参数。所以缩小范围能够更准确地识别参数。

把 X30 改成 X7 即可得到

```
int64_t _base64_decode(int64_t a1, uint32_t a2, int64_t a3, int64_t
a4, int64_t a5, int64_t a6);
int64_t _base64_encode(int64_t a1, uint32_t a2, int64_t a3);
int64_t _test(int64_t a1, int64_t a2, int64_t a3, int64_t a4);
```

```
// General purpose registers
createRegister(ARM64 REG X0, regLt);
createRegister(ARM64 REG X1, regLt);
createRegister(ARM64_REG_X2, _regLt);
createRegister(ARM64 REG X3, regLt);
createRegister(ARM64_REG_X4, _regLt);
createRegister(ARM64 REG X5, regLt);
createRegister(ARM64_REG_X6, _regLt);
createRegister(ARM64 REG X7, regLt);
createRegister(ARM64_REG_X8, _regLt);
createRegister(ARM64 REG X9, regLt);
createRegister(ARM64 REG X10, regLt);
createRegister(ARM64 REG X11, regLt);
createRegister(ARM64 REG_X12, _regLt);
createRegister(ARM64 REG X13, regLt);
createRegister(ARM64 REG X14, regLt);
createRegister(ARM64_REG_X15, _regLt);
createRegister(ARM64 REG X16, regLt);
createRegister(ARM64 REG X17, regLt);
createRegister(ARM64 REG X18, regLt);
createRegister(ARM64_REG_X19, _regLt);
createRegister(ARM64 REG X20, regLt);
createRegister(ARM64_REG_X21, _regLt);
createRegister(ARM64 REG X22, regLt);
createRegister(ARM64_REG_X23, _regLt);
createRegister(ARM64 REG X24, regLt);
createRegister(ARM64_REG_X25, _regLt);
createRegister(ARM64_REG_X26, _regLt);
createRegister(ARM64_REG_X27, _regLt);
createRegister(ARM64_REG_X28, _regLt);
```

在 arm/arm64.cpp 中,通用寄存器只有 X0~X28,所以范围只需要保持在这之间即可,把 X30 改成 X28 也能够解决问题。

2.2.3 优化目标 2

分析. II 文件中 byteswap32 to host 函数的调用者发现它自身并不接受任何参数。

2.3 任务 3: 改进反编译器

任务 2.2.2 中修复 bug 后,参数仍然存在问题,无法识别出来 const